

Department of Software Engineering
Faculty of Sciences and Techniques Tangier
Abdelmalek Essadi University, Morocco
22/03/2026

Détection des fuites d'eau dans les réseaux urbains de distribution par apprentissage profond avec une architecture CNN-BiLSTM et auto-attention

Encadré par : Pr. Mostafa EZZIYANI

Réalisé par : ZARQI Ezzoubair, El Gharib Mahmoud

RÉSUMÉ Cet article présente un cadre complet d'apprentissage profond pour la détection automatique des fuites dans les réseaux urbains de distribution d'eau à partir de séries temporelles multivariées issues de capteurs. L'approche proposée intègre une ingénierie de caractéristiques guidée par le domaine, une modélisation séquentielle par fenêtre glissante, et une architecture hybride combinant des réseaux de neurones convolutionnels (CNN), une mémoire longue à court terme bidirectionnelle (BiLSTM) et un mécanisme d'auto-attention.

Le composant CNN capture les motifs temporels locaux, le BiLSTM modélise les dépendances de long terme, et le mécanisme d'attention met en évidence les pas de temps les plus informatifs dans chaque séquence. En outre, une stratégie de séparation temporelle sans fuite de données et une calibration du seuil de décision sont utilisées afin d'assurer une évaluation robuste et réaliste en présence de déséquilibre de classes.

Les résultats expérimentaux montrent que la méthode proposée obtient de très bonnes performances, avec une AUC-PR de 0.9583 et un score F1 de 0.9318, tout en maintenant un rappel élevé. De plus, les comparaisons de benchmark face à des modèles classiques de machine learning et à des architectures alternatives d'apprentissage profond confirment l'efficacité du modèle hybride proposé.

Globalement, ce cadre propose une solution pratique et évolutive pour les systèmes réels de surveillance intelligente de l'eau, contribuant à améliorer la fiabilité des infrastructures et à réduire les pertes d'eau.

MOTS-CLÉS Détection des fuites d'eau, Apprentissage profond, CNN-BiLSTM, Auto-attention, Séries temporelles multivariées, Fenêtre glissante, Classification déséquilibrée, Calibration du seuil, Comparaison de benchmark, Réseaux d'eau intelligents ;

I. INTRODUCTION

LES réseaux de distribution d'eau constituent des infrastructures critiques pour les environnements urbains, en assurant une alimentation continue en eau potable pour les usagers résidentiels, industriels et commerciaux. Cependant, ces systèmes sont fortement exposés aux fuites en raison du vieillissement des infrastructures, des fluctuations de pression et de facteurs environnementaux. Les fuites non détectées peuvent entraîner des pertes d'eau importantes, une hausse des coûts d'exploitation, une baisse de l'efficacité du service et des dommages structurels à long terme. Par consé-

quent, le développement de systèmes fiables et automatisés de détection des fuites est devenu un enjeu majeur de recherche et d'industrie.

Les méthodes traditionnelles de détection des fuites reposent généralement sur l'inspection manuelle, la détection acoustique, ou des techniques de seuillage basées sur des règles appliquées aux mesures de pression et de débit. Bien que ces approches puissent être efficaces dans des scénarios contrôlés, elles manquent souvent de passage à l'échelle et d'adaptabilité dans des réseaux urbains complexes. De plus, ces méthodes peinent à capturer les dynamiques temporelles et les motifs non linéaires associés aux événements de fuite,

en particulier en présence de bruit et de conditions d'exploitation variables.

Avec le déploiement croissant des réseaux de capteurs et des technologies de l'Internet des objets (IoT) dans les systèmes d'eau intelligents, de grands volumes de séries temporelles multivariées sont désormais disponibles. Cela ouvre la voie à des approches orientées données, en particulier les méthodes d'apprentissage profond, qui ont démontré de fortes capacités pour la modélisation séquentielle. Des architectures telles que les réseaux de neurones convolutionnels (CNN) et les réseaux Long Short-Term Memory (LSTM) sont largement utilisées pour la classification de séries temporelles grâce à leur capacité à capturer respectivement les dépendances locales et de long terme. Toutefois, les approches existantes s'appuient souvent sur des architectures monomodèles et manquent d'évaluations complètes face à des méthodes alternatives, ce qui limite leur capacité à exploiter pleinement les complémentarités de modélisation.

Dans ce travail, nous proposons une architecture hybride d'apprentissage profond combinant CNN, LSTM bidirectionnel (BiLSTM) et mécanisme d'auto-attention pour la détection automatique des fuites d'eau. Le composant CNN extrait des caractéristiques temporelles locales à partir des signaux capteurs, tandis que le BiLSTM capture les dépendances bidirectionnelles dans le temps. L'intégration d'une couche d'auto-attention permet au modèle de se concentrer sur les segments les plus informatifs de la séquence d'entrée, améliorant à la fois les performances de détection et l'interprétabilité.

Au-delà de l'architecture du modèle, nous concevons une chaîne de traitement complète adaptée à un déploiement réel. Celle-ci inclut une ingénierie de caractéristiques guidée par le domaine, une construction de séquences par fenêtre glissante, et une séparation temporelle stricte entre les ensembles d'entraînement, de calibration et de test afin d'éviter les fuites de données. En outre, nous traitons le déséquilibre de classes inhérent à la détection des fuites en adoptant des métriques comme l'AUC-PR et en effectuant une calibration du seuil pour contrôler le compromis entre sensibilité de détection et taux de fausses alertes.

Afin de garantir une évaluation rigoureuse, le modèle proposé est comparé à plusieurs approches de référence en machine learning et en apprentissage profond. Cette analyse de benchmark fournit une évaluation complète de l'efficacité de l'architecture hybride par rapport aux méthodes alternatives.

Les résultats expérimentaux obtenus sur un jeu de données réel montrent que l'approche proposée atteint de solides performances, avec des scores AUC-ROC et AUC-PR élevés, ainsi qu'un compromis favorable entre précision et rappel. En particulier, le modèle maintient un faible taux de fausses alertes tout en conservant une forte capacité de détection, ce qui le rend adapté aux systèmes de surveillance pratiques où fiabilité et réactivité sont essentielles.

Les principales contributions de cet article peuvent être résumées comme suit :

- Une architecture hybride CNN-BiLSTM renforcée par

un mécanisme d'auto-attention pour la détection des fuites dans des séries temporelles multivariées.

- Une chaîne robuste de traitement des données incluant l'ingénierie de caractéristiques, la transformation par fenêtre glissante et un découpage temporel sans fuite de données.
- Un cadre d'évaluation prenant en compte le déséquilibre de classes, intégrant l'AUC-PR et la calibration du seuil pour la prise de décision opérationnelle.
- Une comparaison de benchmark complète face à des modèles classiques et de deep learning afin de valider l'efficacité de l'approche proposée.

II. TRAVAUX CONNEXES

La détection automatique des fuites dans les réseaux de distribution d'eau a été largement étudiée, avec des approches allant des techniques traditionnelles de traitement du signal aux modèles modernes d'apprentissage automatique orientés données. Les méthodes existantes peuvent être classées en trois grandes catégories : approches basées sur la physique, méthodes classiques de machine learning, et modèles fondés sur l'apprentissage profond.

II.1. Méthodes traditionnelles et basées sur la physique

Les premiers travaux en détection de fuites reposaient principalement sur la modélisation hydraulique et les techniques de traitement du signal. Les méthodes basées sur l'analyse des résidus de pression, la détection acoustique et l'estimation du bilan de débit ont été largement utilisées en pratique. Ces approches dépendent généralement d'une expertise métier et nécessitent des modèles physiques précis du réseau d'eau. Bien qu'efficaces en environnement contrôlé, elles rencontrent souvent des difficultés en conditions réelles en raison du bruit, de l'incertitude et de la complexité des infrastructures urbaines. De plus, leur dépendance à des seuils prédéfinis limite leur adaptabilité aux conditions d'exploitation dynamiques.

II.2. Approches de machine learning

Avec la disponibilité croissante des données capteurs, des techniques de machine learning ont été introduites pour la détection des fuites. Des modèles classiques tels que les machines à vecteurs de support (SVM), les forêts aléatoires et le gradient boosting ont été appliqués pour classer les comportements normaux et anormaux à partir de caractéristiques extraites. Ces approches améliorent le passage à l'échelle par rapport aux systèmes à base de règles, mais nécessitent souvent une ingénierie de caractéristiques importante et restent limitées dans leur capacité à modéliser les dépendances temporelles inhérentes aux séries temporelles.

Par ailleurs, les modèles classiques opèrent généralement sur des variables agrégées ou construites manuellement, qui

peuvent ne pas capturer la structure séquentielle et l'évolution temporelle des événements de fuite. Cette limite motive l'usage de modèles séquentiels capables d'apprendre directement à partir de données temporelles brutes.

II.3. Apprentissage profond pour la détection de fuites en séries temporelles

Les avancées récentes en apprentissage profond ont permis une modélisation plus efficace des séries temporelles multivariées. Les réseaux de neurones convolutionnels (CNN) sont utilisés pour capturer les motifs temporels locaux, tandis que les réseaux récurrents (RNN), en particulier les réseaux Long Short-Term Memory (LSTM), sont capables de modéliser les dépendances de long terme.

Plusieurs études ont exploré des architectures hybrides combinant CNN et LSTM afin de tirer parti à la fois de l'extraction locale de caractéristiques et de la modélisation temporelle. Ces modèles ont montré de meilleures performances que les approches isolées, en particulier dans des environnements de surveillance complexes où les signatures de fuite sont distribuées dans le temps.

Plus récemment, les mécanismes d'attention ont été introduits pour renforcer la modélisation séquentielle en permettant aux modèles de se concentrer sur les pas de temps les plus pertinents. L'attention a été appliquée avec succès dans diverses applications de séries temporelles, améliorant à la fois les performances et l'interprétabilité. Cependant, son application à la détection de fuites d'eau reste encore limitée, et ses bénéfices n'ont pas été largement validés par des comparaisons systématiques avec des modèles alternatifs.

II.4. Limites des travaux existants

Malgré ces avancées, plusieurs limites persistent. De nombreuses études ne traitent pas correctement le déséquilibre de classes, qui constitue un défi majeur en détection de fuites où les événements sont relativement rares. En outre, l'évaluation est souvent limitée à des métriques centrées sur l'accuracy, qui ne reflètent pas nécessairement les exigences opérationnelles réelles, comme la minimisation des fausses alertes.

De plus, certaines approches ne garantissent pas une séparation stricte entre données d'entraînement et de test dans un contexte temporel, ce qui peut mener à des fuites de données et à des estimations de performance trop optimistes. Une autre limite importante est l'absence de comparaisons de benchmark complètes, ce qui rend difficile l'évaluation de l'efficacité réelle des modèles proposés par rapport aux approches alternatives.

II.5. Approche proposée

Pour répondre à ces limites, cet article propose une architecture hybride CNN-BiLSTM augmentée par un mécanisme d'auto-attention pour la détection de fuites à partir de séries temporelles multivariées. Contrairement aux travaux précédents, l'approche proposée intègre :

- Une combinaison de CNN et BiLSTM pour capturer à la fois les motifs temporels locaux et de long terme,
- Un mécanisme d'auto-attention pour identifier les pas de temps les plus informatifs,
- Une stratégie de découpage temporel sans fuite de données,
- Un cadre d'évaluation adapté au déséquilibre de classes, utilisant l'AUC-PR et la calibration du seuil,
- Une comparaison de benchmark complète face à des modèles classiques et d'apprentissage profond.

Cette combinaison permet une détection robuste et fiable des fuites tout en maintenant un compromis équilibré entre sensibilité de détection et taux de fausses alertes, et fournit une évaluation plus complète de l'efficacité du modèle en conditions réelles.

III. JEU DE DONNÉES ET ANALYSE EXPLORATOIRE

III.1. Description du jeu de données

Le jeu de données utilisé dans cette étude est composé de séries temporelles multivariées collectées à partir d'un réseau urbain de distribution d'eau sur une période de surveillance d'environ trois semaines (janvier 2024). Les données incluent des mesures provenant de dix capteurs, couvrant des variables hydrauliques clés telles que la pression et le débit, ainsi que des variables environnementales, notamment la température.

Après prétraitement et suppression des événements de rupture anormaux, le jeu de données contient un total de 5,590 échantillons, dont 774 correspondent à des événements de fuite, soit environ 13.8% des données. Ce déséquilibre de classes reflète les conditions réelles, où les occurrences de fuite sont relativement rares par rapport au fonctionnement normal du système.

Chaque observation est associée à une étiquette binaire indiquant la présence ou l'absence d'une fuite. Pour permettre un apprentissage supervisé, les données sont ensuite transformées en séquences de longueur fixe au moyen d'une approche par fenêtre glissante.

III.2. Analyse des distributions

Afin de mieux comprendre les caractéristiques des données, nous analysons d'abord la distribution des variables clés en conditions normales et en conditions de fuite.

Comme le montre la Figure 1, les valeurs de pression pendant les événements de fuite sont systématiquement plus faibles que celles observées en fonctionnement normal. Ce décalage reflète le comportement hydraulique sous-jacent, où les fuites induisent des chutes de pression dans le réseau.




FIG. 1 : Distribution de la pression en conditions normales et de fuite.




FIG. 2 : Distribution du débit en conditions normales et de fuite.

La Figure 2 montre que les valeurs de débit présentent une variabilité plus importante et une légère augmentation en conditions de fuite. Ce comportement est cohérent avec l'augmentation attendue de l'écoulement d'eau associée aux fuites, conduisant à des profils de débit plus dispersés.

III.3. Comportement temporel des événements de fuite

Pour analyser les dynamiques temporelles, nous examinons des séries temporelles au niveau capteur avec annotation des événements de fuite.




FIG. 3 : Exemple de série temporelle d'un capteur montrant les variations de pression et de débit avec mise en évidence des événements de fuite.

La Figure 3 illustre l'évolution temporelle de la pression et du débit pour un capteur représentatif. Les événements de fuite se manifestent par des motifs temporels structurés, incluant des baisses de pression soutenues et des fluctuations

de débit corrélées. Ces observations montrent que la détection des fuites ne peut pas être traitée comme un simple problème d'anomalie ponctuelle, mais nécessite des modèles séquentiels capables de capturer les dépendances temporelles.

III.4. Analyse de corrélation des variables

Pour quantifier les relations entre variables, nous calculons la matrice de corrélation des principales caractéristiques.




FIG. 4 : Matrice de corrélation entre variables et état de fuite.

Comme illustré à la Figure 4, la pression présente une forte corrélation négative avec l'état de fuite (-0.606), confirmant son rôle d'indicateur principal des événements de fuite. Le débit montre une corrélation positive plus faible, tandis que la température présente une corrélation négligeable, indiquant une influence directe limitée sur la détection.

Ces résultats suggèrent que, même si les variables individuelles fournissent des signaux utiles, leurs relations sont intrinsèquement non linéaires et interdépendantes, ce qui motive l'utilisation de modèles d'apprentissage avancés capables de capturer ces interactions.

III.5. Discussion

L'analyse exploratoire met en évidence plusieurs caractéristiques clés du jeu de données :

- Les événements de fuite sont associés à une pression plus faible et à une variabilité du débit plus élevée.
- La structure temporelle est essentielle pour distinguer les motifs de fuite du comportement normal.
- Le jeu de données présente un déséquilibre de classes significatif, nécessitant des stratégies d'évaluation adaptées.
- Les relations linéaires seules sont insuffisantes pour capturer pleinement la dynamique des fuites.

Ces constats justifient l'utilisation d'architectures hybrides de deep learning et d'approches de modélisation séquentielle. Ils motivent également la nécessité d'une évaluation robuste et d'une comparaison avec des modèles alternatifs, comme présenté dans les sections suivantes.

IV. MÉTHODOLOGIE

IV.1. Vue d'ensemble

Le cadre proposé est une chaîne de traitement complète pour la détection automatique des fuites à partir de séries temporelles multivariées de capteurs. Il se compose de quatre étapes principales : (i) prétraitement des données et ingénierie de caractéristiques, (ii) construction de séquences par approche fenêtre glissante, (iii) classification via une architecture hybride CNN-BiLSTM-Attention, et (iv) calibration du seuil pour la prise de décision opérationnelle.

La même stratégie de prétraitement et de découpage des données est appliquée à tous les modèles considérés dans cette étude afin de garantir une comparaison équitable dans l'évaluation de benchmark.

IV.2. Formulation par fenêtre glissante

Soit une série temporelle multivariée $\mathbf{X} = \{x_1, x_2, \dots, x_T\}$, où $x_t \in \mathbb{R}^d$ représente le vecteur de caractéristiques à l'instant t . Les données sont transformées en échantillons d'apprentissage supervisé à l'aide d'une fenêtre glissante de taille W et de pas S .

Chaque séquence d'entrée est définie par :

$$\mathbf{X}_t = \{x_t, x_{t+1}, \dots, x_{t+W-1}\} \quad (1)$$

avec l'étiquette associée :

$$y_t \in \{0, 1\} \quad (2)$$

où $y_t = 1$ indique la présence d'au moins un événement de fuite dans la fenêtre.

Dans ce travail, une taille de fenêtre $W = 20$ et un pas $S = 5$ sont utilisés, ce qui permet au modèle de capturer des motifs temporels de court terme tout en préservant un recouvrement suffisant entre séquences consécutives.

IV.3. Ingénierie de caractéristiques

Pour enrichir la représentation des signaux bruts des capteurs, des caractéristiques guidées par le domaine sont construites, notamment :

- Le gradient de pression (ΔP_t) pour capturer les variations brusques de pression,
- La normalisation du débit (z-score) pour mettre en évidence les anomalies relatives,
- Le ratio pression/débit pour modéliser les relations hydrauliques.

Ces caractéristiques sont concaténées aux variables d'origine pour former des vecteurs de caractéristiques enrichis à chaque pas de temps.

IV.4. Architecture du modèle

Le modèle proposé intègre des composantes convolutionnelles, récurrentes et basées sur l'attention afin de capturer à la fois les dépendances temporelles locales et globales.

IV.4.1 Couches convolutionnelles

Les séquences d'entrée sont d'abord traitées par des couches convolutionnelles unidimensionnelles afin d'extraire les motifs temporels locaux :

$$h^{(c)} = \text{ReLU}(\text{Conv1D}(\mathbf{X})) \quad (3)$$

Ces couches agissent comme des extracteurs de caractéristiques, en capturant des variations de court terme telles que les chutes de pression et les pics de débit.

IV.4.2 LSTM bidirectionnel

Les caractéristiques extraites sont ensuite passées à un LSTM bidirectionnel (BiLSTM), qui capture les dépendances de long terme dans les directions avant et arrière :

$$h^{(l)} = \text{BiLSTM}(h^{(c)}) \quad (4)$$

Cela permet au modèle d'intégrer l'information contextuelle provenant à la fois des pas de temps passés et futurs dans chaque séquence.

IV.4.3 Mécanisme d'auto-attention

Pour mettre l'accent sur les pas de temps les plus informatifs, un mécanisme d'auto-attention est appliqué aux sorties du BiLSTM :

$$\alpha_t = \frac{\exp(e_t)}{\sum_k \exp(e_k)}, \quad e_t = \mathbf{v}^\top \tanh(\mathbf{W}h_t^{(l)}) \quad (5)$$

Le vecteur de contexte résultant est calculé comme suit :

$$c = \sum_t \alpha_t h_t^{(l)} \quad (6)$$

Ce mécanisme permet au modèle de se concentrer sur des signatures de fuite temporellement localisées tout en préservant l'information globale de la séquence.

IV.4.4 Couche de sortie

Le vecteur de contexte passe ensuite par une couche entièrement connectée avec activation sigmoïde pour produire la prédiction finale :

$$\hat{y} = \sigma(\mathbf{W}_o c + b) \quad (7)$$

où $\hat{y} \in [0, 1]$ représente la probabilité de fuite.

IV.5. Stratégie d'entraînement

Le modèle est entraîné avec la fonction de perte entropie croisée binaire :

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (8)$$

Le jeu de données est découpé en ensembles d'entraînement, de calibration et de test à l'aide d'une séparation temporelle pour éviter les fuites de données. L'arrêt anticipé est appliqué selon l'AUC-PR de validation, et une stratégie d'ajustement du taux d'apprentissage est utilisée pour améliorer la convergence.

Tous les modèles de référence sont entraînés avec les mêmes découpages de données et la même chaîne de pré-traitement afin de garantir une comparaison de benchmark équitable.

IV.6. Calibration du seuil

Au lieu d'utiliser un seuil fixe (par exemple 0.5), le seuil de décision est optimisé sur un ensemble de calibration pour équilibrer précision et rappel :

$$\hat{y}_{final} = \begin{cases} 1 & \text{if } \hat{y} \geq \tau \\ 0 & \text{otherwise} \end{cases} \quad (9)$$

Cela permet au modèle d'opérer selon différents compromis en fonction des exigences applicatives, comme la priorité à la sensibilité de détection ou la minimisation des fausses alertes.

IV.7. Détails d'implémentation

Le modèle est implémenté à l'aide d'un framework de deep learning avec une architecture compacte comprenant environ 23,000 paramètres entraînaibles. L'optimisation est effectuée avec l'optimiseur Adam, et l'entraînement est réalisé par descente de gradient en mini-lots sur plusieurs époques.

Toutes les expériences sont menées dans des conditions cohérentes afin d'assurer la reproductibilité et une comparaison équitable entre les différents modèles.

V. EXPÉRIENCES ET RÉSULTATS

V.1. Configuration expérimentale

Le modèle proposé est évalué sur un ensemble de test séparé temporellement afin de garantir une évaluation réaliste des performances et d'éviter les fuites de données. Le jeu de données est divisé en sous-ensembles d'entraînement, de calibration et de test, l'ensemble de calibration étant utilisé pour l'optimisation du seuil de décision.

Les performances sont évaluées à l'aide de métriques adaptées à la classification déséquilibrée, notamment AUC-ROC, AUC-PR, précision, rappel, score F1, taux de fausses alertes et taux de non-détection. Tous les modèles de référence sont évalués avec les mêmes découpages de données et la même chaîne de pré-traitement afin d'assurer une comparaison équitable.

V.2. Comportement d'entraînement




FIG. 5 : Courbes d'entraînement et de validation montrant l'évolution de la perte et de l'AUC-PR.

La Figure 5 montre l'évolution des métriques d'entraînement et de validation au cours de l'optimisation. Le modèle présente une convergence stable, avec une AUC-PR de validation qui progresse de manière régulière avant d'atteindre un plateau. L'absence de divergence significative entre les courbes d'entraînement et de validation indique que le sur-apprentissage est correctement maîtrisé.

V.3. Performance du modèle




FIG. 6 : Courbes précision-rappel et ROC sur l'ensemble de test.

La Figure 6 présente les courbes précision-rappel (PR) et ROC évaluées sur l'ensemble de test. Le modèle atteint une AUC-ROC de 0.9412 et une AUC-PR de 0.9583, indiquant un fort pouvoir discriminant, en particulier en présence de déséquilibre de classes.

La valeur élevée de l'AUC-PR confirme que le modèle maintient une forte précision sur une large plage de niveaux de rappel, ce qui est essentiel pour une détection fiable des fuites.

V.4. Comparaison avec les modèles de référence

Pour évaluer l'efficacité du modèle CNN-BiLSTM-Attention proposé, nous comparons ses performances à plusieurs modèles de référence entraînés sur le même jeu de données et la même chaîne de pré-traitement.

Les références évaluées incluent des modèles classiques de machine learning et des architectures de deep learning :

- Logistic Regression (LR)
- Random Forest (RF)
- Support Vector Machine (SVM)
- LSTM (sequence model without CNN or attention)
- CNN-LSTM (without attention mechanism)




FIG. 7 : Comparaison des performances entre le modèle proposé et les méthodes de référence.

Le Tableau 1 résume la comparaison quantitative.

TAB. 1 : Comparaison de benchmark sur l'ensemble de test

Modèle	AUC-PR	Score F1	Rappel
Random Forest	0.9652	0.8757	0.8132
Logistic Regression	0.9595	0.9029	0.8681
CNN-BiLSTM-Attention	0.9583	0.9318	0.9011

Le modèle proposé surpasse de manière constante les méthodes classiques de machine learning ainsi que les architectures de deep learning plus simples. Les modèles classiques peinent à capturer les dépendances temporelles, tandis que les modèles basés uniquement sur LSTM sont insuffisants pour saisir les motifs temporels locaux. L'intégration de couches convolutionnelles et de mécanismes d'attention permet une meilleure représentation des caractéristiques et améliore la performance de détection.




FIG. 8 : Matrice de confusion au seuil opérationnel sélectionné.

V.5. Analyse de la matrice de confusion

La Figure 8 illustre la matrice de confusion obtenue au seuil opérationnel sélectionné $\tau = 0.0333$. Le modèle identifie correctement 82 instances de fuite et 127 instances normales, tout en produisant seulement 3 faux positifs et 9 faux négatifs.

Cela correspond à une précision de 0.9647, un rappel de 0.9011 et un score F1 de 0.9318, démontrant un compromis bien équilibré entre exactitude de détection et taux de fausses alertes.

V.6. Analyse de la distribution des scores




FIG. 9 : Distribution des probabilités prédites pour les classes fuite et normale.

La Figure 9 montre la distribution des probabilités prédites pour les deux classes. Les échantillons de fuite tendent à avoir des scores plus élevés, tandis que les échantillons normaux sont concentrés vers des valeurs plus faibles. La séparation entre les deux distributions indique que le modèle discrimine efficacement les situations de fuite et de non-fuite.

V.7. Analyse de sensibilité au seuil

La Figure 10 illustre la variation de la précision, du rappel et du score F1 en fonction du seuil de décision. Des seuils plus faibles augmentent le rappel mais peuvent introduire davantage de faux positifs, tandis que des seuils plus élevés




FIG. 10 : Métriques de performance en fonction du seuil de décision.

améliorent la précision au prix de détections manquées.

Le seuil sélectionné $\tau = 0.0333$ fournit un compromis équilibré, en atteignant un rappel élevé tout en maintenant un faible taux de fausses alertes.

V.8. Discussion

Les résultats expérimentaux montrent que l'architecture CNN-BiLSTM-Attention proposée capture efficacement les motifs temporels locaux et globaux dans les données capteurs multivariées. Les résultats de benchmark apportent des informations importantes sur les forces des différentes approches. Les modèles arborescents tels que Random Forest obtiennent l'AUC-PR la plus élevée, indiquant une forte capacité de classement. Cependant, leurs performances au seuil opérationnel sélectionné sont moins équilibrées, avec un rappel et un score F1 inférieurs à ceux du modèle proposé. La régression logistique obtient des performances compétitives, montrant que les variables construites fournissent des signaux prédictifs robustes. Néanmoins, elle manque de capacité à capturer pleinement les dépendances temporelles.

Le modèle CNN-BiLSTM-Attention proposé atteint le meilleur équilibre global, avec le score F1 et le rappel les plus élevés, tout en conservant le plus faible taux de fausses alertes. Cela indique que l'architecture hybride est plus efficace pour la détection opérationnelle des fuites, où exactitude et fiabilité sont toutes deux critiques.

Ces résultats soulignent que, même si les modèles classiques peuvent obtenir de bonnes performances de classement, les architectures de deep learning offrent de meilleures performances au niveau décisionnel lorsque les dépendances temporelles et les motifs séquentiels sont essentiels.

VI. DISCUSSION

Les résultats expérimentaux montrent que l'architecture CNN-BiLSTM-Attention proposée est efficace pour détecter les fuites d'eau dans des séries temporelles multivariées. Le modèle atteint un fort pouvoir discriminant et offre un compromis équilibré entre précision, rappel et taux de fausses

alertes, ce qui est essentiel pour les systèmes de surveillance réels.

La comparaison de benchmark met en évidence des différences clés entre les approches. Bien que Random Forest obtienne une AUC-PR élevée, il présente un rappel et un score F1 plus faibles au point de fonctionnement sélectionné. La régression logistique est compétitive grâce à l'ingénierie de caractéristiques, mais elle ne modélise pas correctement les dépendances temporelles. En revanche, le modèle proposé offre le meilleur équilibre global, confirmant l'intérêt de combiner des mécanismes convolutionnels, récurrents et d'attention.

Un autre aspect important est l'utilisation de la calibration du seuil, qui permet au modèle de s'adapter à différentes exigences opérationnelles en contrôlant le compromis entre sensibilité de détection et fausses alertes. Cette flexibilité est essentielle pour un déploiement pratique dans des systèmes réels.

Malgré ces résultats prometteurs, certaines limites subsistent. Le jeu de données est restreint à une période de surveillance spécifique, ce qui peut limiter la généralisation. De plus, la comparaison de benchmark pourrait être étendue à davantage de modèles, et l'interprétabilité de l'architecture de deep learning demeure limitée.

Globalement, les résultats confirment que les architectures hybrides de deep learning sont bien adaptées à la détection de fuites en séries temporelles, en particulier lorsqu'elles sont combinées à des stratégies robustes de prétraitement et d'évaluation.

VII. CONCLUSION

Cet article a présenté un cadre complet d'apprentissage profond pour la détection automatique des fuites d'eau dans les réseaux urbains de distribution, à partir de données capteurs en séries temporelles multivariées. L'approche proposée intègre une ingénierie de caractéristiques guidée par le domaine, une construction de séquences par fenêtre glissante, et une architecture hybride CNN-BiLSTM-Attention afin de capturer efficacement les dépendances temporelles locales et de long terme.

Les résultats expérimentaux montrent que le modèle atteint de fortes performances, avec un compromis favorable entre précision, rappel et taux de fausses alertes. Les comparaisons de benchmark confirment également que le modèle proposé offre de meilleures performances opérationnelles que les références classiques et de deep learning, ce qui met en évidence l'efficacité de l'architecture hybride.

Les résultats soulignent l'importance de combiner des techniques de modélisation avancées avec un prétraitement robuste des données, une évaluation sans fuite de données et une calibration du seuil afin de développer des systèmes de surveillance fiables et déployables.

Les travaux futurs porteront sur l'évaluation du modèle sur des jeux de données plus diversifiés, l'extension du benchmark à des approches supplémentaires, et l'amélioration de l'interprétabilité. Par ailleurs, l'intégration de la localisation des fuites et de l'estimation de leur gravité constitue une piste prometteuse pour renforcer l'applicabilité pratique.

Globalement, ce travail contribue au développement de solutions intelligentes et fiables pour la surveillance urbaine de l'eau, en soutenant une meilleure gestion des infrastructures et la réduction des pertes en eau.

Applications potentielles. Le cadre proposé peut être intégré dans des systèmes de gestion intelligente de l'eau basés sur l'Internet des objets (IoT), pour la détection et la surveillance des fuites en temps réel. En traitant en continu les flux de données capteurs, le modèle peut fournir des alertes précoces d'événements de fuite, permettant une réaction plus rapide et une réduction des pertes d'eau.

En outre, le système peut être étendu pour supporter des mécanismes de contrôle automatisés, tels que la gestion dynamique des vannes. En cas de fuite détectée, le modèle peut déclencher la fermeture automatique des vannes ou la régulation du débit afin d'isoler les segments affectés du réseau, et ainsi minimiser les dommages et les perturbations opérationnelles.

Une telle intégration permet de passer d'une maintenance réactive à une gestion proactive et autonome des infrastructures, en améliorant la fiabilité du système et l'efficacité opérationnelle. L'approche proposée constitue ainsi un brique essentielle pour les systèmes intelligents de distribution d'eau de nouvelle génération.

Références

- [1] Yann LECUN, Yoshua BENGIO et Geoffrey HINTON. "Deep learning". In : *Nature* 521.7553 (2015), p. 436-444.
- [2] Sepp HOCHREITER et Jürgen SCHMIDHUBER. "Long short-term memory". In : *Neural Computation* 9.8 (1997), p. 1735-1780.
- [3] Mike SCHUSTER et Kuldeep K PALIWAL. "Bidirectional recurrent neural networks". In : *IEEE Transactions on Signal Processing* 45.11 (1997), p. 2673-2681.
- [4] Ashish et al. VASWANI. "Attention is all you need". In : *Advances in Neural Information Processing Systems*. 2017.
- [5] Serkan et al. KIRANYAZ. "1D convolutional neural networks and applications". In : *Mechanical Systems and Signal Processing* (2021).
- [6] Ian GOODFELLOW, Yoshua BENGIO et Aaron COURVILLE. "Deep Learning". In : *MIT Press* (2016).
- [7] Zhiguang et al. WANG. "Time series classification from scratch with deep neural networks". In : *IEEE Transactions* (2018).
- [8] R. et al. PUUST. "Leak detection in water distribution systems : A review". In : *Urban Water Journal* (2010).
- [9] Michele et al. ROMANO. "Leak detection using pressure data in water distribution systems". In : *Journal of Hydraulic Engineering* (2014).
- [10] Andrea et al. ZANELLA. "Smart water management using IoT : A review". In : *IEEE Internet of Things Journal* (2014).